

‘G) 1/2 , ‘ג גן

נִזְמָן : כָּלֵב

206867517 : 3.11

(Step-Size Perceptron) :  $\alpha/k$

רְגִזְעַן יָמִינֵי כְּלָבֶשֶׂת לְבָנָה אֲלֵין :

$\|w^*\|_2 = 1$ ,  $w^*$  is a unit vector.

गर्वानि धर्माद्यो विश्वासा विश्वासा विश्वासा

Algorithm 2:  $\text{Solve}_{\text{NN}}(\mathcal{F}_{\text{NN}})$

.(נולא נסבון) הוא מושג כלשהו כ' (בנוסף ל-)

רְמָה מִלְּאָכָל אֲבָנָה בְּבֵית יְהוָה

$$w_{f+1} \cdot w^* \geq M \cdot r$$

$$w_{t+1} \cdot w^* = (w_t + \eta_t y_t x_t) w^* = w_t \cdot w^* + \eta_t y_t x_t w^* =$$

(1/2) (1/2) (1/2)

## Step-Size Perceptron

$$w_t w^* + \eta_t (y_t x_t \cdot w^*) = w_t w^* - \frac{1}{\sqrt{t}} (y_t x_t \cdot w^*) \geq w_t w^* - \frac{\gamma}{\sqrt{t}} |r|$$

$\eta_t$   
Noise  
 $y_t x_t \cdot w^*$

$$W_t \cdot W^* \geq \sum_{t=1}^M \frac{1}{\sqrt{t}} \cdot 1 \quad : \text{using M times } |0|$$

$$= \gamma \sum_{t=1}^M \frac{1}{\sqrt{t}} \geq \gamma \cdot \cancel{\sqrt{M}} \cdot \frac{1}{\cancel{\sqrt{M}}} = \boxed{\gamma \sqrt{M}}$$

: proof now  $t \in [M]$  so  $\gamma \sqrt{M}$  and  $\|W_t\|_2 \leq \gamma \sqrt{M}$ . 2;

$$\|W_{t+1}\|_2^2 = \|W_t + \eta_t x_t y_t + x_t\|_2^2 = \|W_t\|_2^2 + 2 W_t \cdot \eta_t x_t y_t + \|\eta_t x_t y_t\|_2^2$$

using  $\|x_t\|_2 = 1$   
and  $y_t \in \{-1, +1\}$

$y_t W_t x_t < 0$  by  $y_t \in \{-1, +1\}$  for  $t \in [M]$  so, proof

$$\|W_{t+1}\|_2^2 \geq \|W_t\|_2^2 + 2 W_t \cdot \eta_t x_t y_t \geq 0 \quad 0 < \eta_t = \frac{1}{\sqrt{t}} \quad \|x_t\|_2 = 1$$

$$\|W_{t+1}\|_2^2 = \|W_t\|_2^2 + 2 W_t \cdot \eta_t x_t y_t + \|\eta_t x_t y_t\|_2^2 \leq \|W_t\|_2^2 + \frac{1}{t} \|x_t\|_2^2$$

$y_t \in \{-1, +1\}$

so  $\|x_t\|_2 = 1$

$$\|x_t\|_2 = 1$$

: proof  $M$  times

$$\|W_t\|_2^2 \leq \sum_{k=1}^M \frac{1}{k} \leq \underbrace{\sum_{k=1}^{\infty} \frac{1}{k}}_{\substack{\lim_{n \rightarrow \infty} H_n \\ n}} \leq 1 + \ln M$$

: proof

$$\sqrt{M} \leq W_t \cdot W^* \leq \|W_t\|_2 \cdot \|W^*\|_2 = \|W_t\|_2 \leq \sqrt{1 + \ln M} \leq \sqrt{2 \ln M}$$

$M \geq 3$

$$\Rightarrow M \leq \frac{2}{r^2} \ln M \stackrel{\text{def}}{\Rightarrow} M \leq \frac{4}{r^2} \ln \frac{2}{r^2} = O\left(\frac{1}{r^2} \cdot \ln \frac{1}{r^2}\right)$$

(N.D.)

: Proof

$$M \leq \frac{4}{r^2} \ln \left(\frac{1}{r}\right) \quad \text{- e: 112 } t > 0 \quad \text{e: } t = r, \quad M = 0 \quad \text{pk}$$

$$\boxed{11} \quad Y \leq \|W_t\|_2 \cdot \|W^*\|_2 \leq 1 \quad \text{sc: } M = 1 \quad \text{pk}$$

$$t < 4 \cdot \ln 2 \leq \frac{4}{r^2} \cdot \ln \frac{2}{r^2}$$

$$\boxed{12} \quad \|W_t\|_2 \leq 1 \frac{1}{2} \quad \text{sc: } M = 2 \quad \text{pk}$$

$$r = \frac{3}{2-\sqrt{2}}$$

$$M = 2 < \frac{4}{\frac{9}{8}} \cdot \ln \frac{2}{\frac{9}{8}} \leq \frac{4}{r^2} \ln \frac{2}{r^2}$$

$$M = O\left(\frac{1}{r^2} \ln \frac{1}{r^2}\right) \rightarrow N \quad M \geq 0 \quad \text{bk: } \boxed{11} \quad \text{sc: } \boxed{12}$$

■

2) f(x)

ונבון שפונקציית המינימיזציה  $\lambda c_1 + (1-\lambda)c_2$  היא פונקציית אקספלינר (a)

$g: C \rightarrow \mathbb{R}$  :  $g$  היא פונקציית ריבועית על  $C$

הוכיחו כי  $\nabla g(x)$  על  $\mathbb{R}^n \supseteq C := \{Ax+b \mid x \in \mathbb{R}^n\}$  הוא

.  $c_1, c_2 \in C$  ו $\lambda \in (0,1)$  .  $\nabla g(x)$  על  $C$ ;

- $\lambda c_1 + (1-\lambda)c_2$   $\in \mathbb{R}^n$   $\ni x_1, x_2$  ריבועית  $\nabla g(x)$  על  $C$  מגדירה

$$:\mathbb{R}^n \ni x \quad \begin{cases} c_1 = Ax_1 + b \\ c_2 = Ax_2 + b \end{cases}$$

$$\lambda c_1 + (1-\lambda)c_2 = \lambda(Ax_1 + b) + (1-\lambda)(Ax_2 + b)$$

$$= \underbrace{\lambda Ax_1}_{\lambda c_1} + \underbrace{\lambda b}_{\lambda c_2} + \underbrace{(1-\lambda)Ax_2}_{(1-\lambda)c_2} + \underbrace{(1-\lambda)b}_{(1-\lambda)c_2}$$

$$= A(\lambda x_1 + (1-\lambda)x_2) + b$$

: הוכיחו  $g - \lambda c_1 + (1-\lambda)c_2$  על  $C$  מגדירה

:  $\forall \lambda \in [0,1] \quad c_1, c_2 \in C$

$$g(\lambda c_1 + (1-\lambda)c_2) = f(A(\lambda c_1 + (1-\lambda)c_2) + b) =$$
  
$$g(\lambda c_1 + (1-\lambda)c_2) = f(\underbrace{\lambda(Ac_1 + b) + (1-\lambda)(Ac_2 + b)}_{b(\lambda(1-\lambda))})$$

$$f(Ac_1 + b) + (1-\lambda)(Ac_2 + b) \leq \lambda f(Ac_1 + b) + (1-\lambda)(Ac_2 + b)$$

$$g(\lambda c_1 + (1-\lambda)c_2) = \lambda g(c_1) + (1-\lambda)g(c_2)$$

■  $\forall \lambda \in [0,1] \quad g(\lambda c_1 + (1-\lambda)c_2) \leq \max\{g(c_1), g(c_2)\}$

הוכחה ב'  $f_1, \dots, f_m$  (b)

.  
הוכחה ב'  $f_i$  .  $g: \mathbb{R}^d \rightarrow \mathbb{R}$ ,  $g(x) = \max_{i \in [m]} f_i(x)$

הוכחה ב'  $R^d = g \{x \in \mathbb{R}^d \mid$

$(\exists i \in [m]) f_i(x) = g(x)$

:  $\exists \lambda \in (0,1)$  .  $R^d \ni x_1, x_2 \in \mathbb{R}^d$

$g(\lambda x_1 + (1-\lambda)x_2) = \max_{i \in [m]} f_i(\lambda x_1 + (1-\lambda)x_2) \leq \max_{i \in [m]} (\lambda f_i(x_1) + (1-\lambda)f_i(x_2))$

$\leq \lambda \max_{i \in [m]} f_i(x_1) + (1-\lambda) \max_{i \in [m]} f_i(x_2) = \lambda g(x_1) + (1-\lambda)g(x_2)$

■  $\forall \lambda \in [0,1] \quad g(\lambda c_1 + (1-\lambda)c_2) \leq \max\{g(c_1), g(c_2)\}$

.  
הוכחה ב'  $\mathbb{R} \subseteq \mathbb{R}^d$  (c)

$\int_0^{\infty} f_e(\lambda) d\lambda = \int_0^{\infty} e^{-\lambda} \lambda^k d\lambda$  (בordersense)

: ב'  $\int_0^{\infty} e^{-\lambda} \lambda^k d\lambda = \frac{k!}{e^{\infty}}$

$$\int_0^{\infty} f_e(z) dz = \frac{-e^{-z}}{(1+e^{-z})} \int_0^{\infty} dz$$

הנתקה מכם נסב למשך ימים אחדים.

∴  $y = \frac{1}{2}x + 1$   $\text{well}$

$$l_{\log}''(z) = \frac{e^{-z} \cdot (1 + e^{-z}) \ln z - e^{-z} \cdot e^{-z} \ln z}{(1 + e^{-z})^2 \ln^2 z}$$

$$= \frac{e^{-z} (1 + e^{-z} - e^{-z})}{(1 + e^{-z})^2 \ln 2} = \frac{e^{-z}}{(1 + e^{-z}) \ln 2} > 0$$

•  $\log$  (Wen) of  $f(x)$

13)  $\gamma(N A - 1) \quad b = \bar{v} \quad \text{or} \quad (\alpha) \quad \text{from } \bar{v}$

XY -  $\int_{\text{ج}}^{\text{أ}} \text{م}(\text{ل}) \text{د}(\text{ل})$  :  $\int_{\text{ج}}^{\text{أ}} \text{م}(\text{ل}) \text{د}(\text{ل})$   $\int_{\text{ج}}^{\text{أ}} \text{م}(\text{ل}) \text{د}(\text{ل})$   $\int_{\text{ج}}^{\text{أ}} \text{م}(\text{ل}) \text{د}(\text{ل})$

W -  $\int_{\gamma} \alpha(\lambda) \lambda'(\lambda) \text{d}\lambda$   $\int_{\partial D} (y_w x) \rho(x) \text{d}x$

3) fkl

לפיכם מינימיזציה של פונקציית האפסה נזק (alpha)

1-  $\sum_i \text{sgn}(y_j - y_r) w(x_j - x_r) - \ell$  ) מינימיזציה של פונקציית האפסה נזק (alpha)

• פונקציית hinge loss - הינה פונקציית האפסה נזק (alpha)

$\mathbb{R}^d$  מינימיזציה, יהי  $f(w) = 1 - \text{sgn}(y_j - y_r) w(x_j - x_r)$

$w_1, w_2 \in \mathbb{R}^d$  -  $\lambda \in (0, 1)$  מינימיזציה

$$f(\lambda w_1 + (1-\lambda)w_2) = 1 - \text{sgn}(y_j - y_r)(\lambda w_1 + (1-\lambda)w_2)(x_j - x_r)$$

$f(\lambda w_1)$

$$= 1 - \text{sgn}(y_j - y_r)[\lambda w_1(x_j - x_r) + (1-\lambda)w_2 \cdot (x_j - x_r)] =$$

$$= 1 - \lambda \cdot \text{sgn}(y_j - y_r)(w_1 \cdot (x_j - x_r)) + (1-\lambda)\text{sgn}(y_j - y_r)(w_2 \cdot (x_j - x_r))$$

$$= \lambda + 1 - \lambda \cdot \text{sgn}(y_j - y_r)(w_1 \cdot (x_j - x_r)) - (1-\lambda)\text{sgn}(y_j - y_r)(w_2 \cdot (x_j - x_r))$$

$$= \lambda(1 - \text{sgn}(y_j - y_r)(w_1 \cdot (x_j - x_r))) + (1-\lambda)(1 - \text{sgn}(y_j - y_r)(w_2 \cdot (x_j - x_r)))$$

$$= \lambda f(w_1) + (1-\lambda)f(w_2)$$

- מינימיזציה של פונקציית האפסה נזק (alpha)

לפיכם מינימיזציה של פונקציית האפסה נזק (alpha)

לפיכם מינימיזציה של פונקציית האפסה נזק (alpha)

$n - \int_1^n f(x) dx$   $\geq 0$   $\forall n \in \mathbb{N}$

הנ'  $f_1, \dots, f_{n-1}$  מוגדרת כפונקציית גיבוב מ- $\mathbb{R}^n$  ל- $\mathbb{R}^{n-1}$ .

$$\sum_{i=1}^{n-1} f_i + f_n = \sum_{i=1}^n f_i = S$$

;  $N/c$  :  $S/c$

•  $\lim_{n \rightarrow \infty} \int_0^1 f_n(x) dx = \int_0^1 \lim_{n \rightarrow \infty} f_n(x) dx$  (Lebesgue's dominated convergence theorem)

hinge  $\rightarrow$   $\text{הinge}$  (הinge)  $\rightarrow$   $\text{הinge}$  (הinge)

■  $\mathcal{O}(N^k)$  の計算量

$$\Delta(h_w(\bar{x}), y) \leq \ell(h_w(\bar{x}), y) \quad , \quad (b)$$

:  $\rho'' \cap N$  .  $y \in R^k$  -!  $\bar{x} \in X^k$  -!  $w \in R^d$  ;)

$$\Delta(h_w(x^i), y^i) = \max\{0, 1 - \underbrace{\text{Syn}(y_j - y_r)}_{\#} \cdot w(x_j - x_r)\} = \begin{cases} \alpha(y), & \# < 1 \\ 0, & \text{else} \end{cases}$$

$$= \begin{cases} \alpha^{(j)}, & \text{if } \text{sgn}(y_j - y_r) \cdot \text{sgn}(y'_j - y'_r) |y'_j - y'_r| < 1 \\ 0, & \text{else} \end{cases}$$

$$\geq \begin{cases} 1 & : \text{sgn}(y_j - y_r) \neq \text{sgn}(y_j' - y_r') \\ 0 & : \text{else} \end{cases} = 1_{\{\text{sgn}(y_j - y_r) \neq \text{sgn}(y_j' - y_r')\}}$$

$$y \leq 0$$

الله رب العالمين

$$\text{. e) } \forall N \exists \Delta(h_w(\bar{x}), y) \leq \ell(h_w(\bar{x}), y)$$

-  $\int \rho d \rho_{IN} / \rho_{WD}$  Kendal-Tau  $\rightarrow$  ~~use linear interpolation~~

- l p W\* ∈ R^d p..je rsi J γ > 0 pδ → C.C(C,γ)

$$: \text{f}(\bar{x}_j) - \bar{w} = \frac{w^*}{\chi} \quad , \quad \gamma \leq \operatorname{sgn}(y_j - y_r) w^* \cdot (x_j - x_r)$$

$$Sgn(y_j - y_r) \cdot \tilde{W} \cdot (x_j - x_r) = Sgn(y_j - y_r) \cdot \frac{W^*}{r} \cdot (x_j - x_r) \geq 1$$

$$1 - \text{Sign}(y_j - y_r) \cdot \tilde{W}(x_j - x_r) \leq 0$$

$$\Rightarrow \max \{0, 1 - \text{Syn}(y_j - y_r) \cdot \tilde{W}(x_j - x_r)\} = 0$$

לעומת הילדה, מושג זה מתייחס לשליטה על אמצעים ויכולות פיזיולוגיות.

የኢትዮጵያ ከተማ የሚከተሉ ስራውን በቻ የሚከተሉ ስራውን በቻ

الآن نحن في مرحلة تطوير وتحسين المحتوى التعليمي.

Yalla kalkile yun dey . Kendal Tag in also known as Kita  
"NDSN" , Jadi we had o kita ke minjale

■ . LRC Casing fit

: 4) if l

$\Rightarrow$  we have  $\nabla f(x) - \beta$  's 0  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  s.t.

if  $\| \nabla f(x) \|_2 \leq \eta$  AND  $\forall x \in \mathbb{R}^n, f(x) \geq 0$

$$\cdot \lim_{t \rightarrow \infty} \| \nabla f(x_t) \|_2 = 0 \quad \text{since } \frac{\eta^2}{\beta} > 1 \quad \text{or, i.e.}$$

:  $x_t, x_{t+1} \rightarrow$  if  $\rho' \rightarrow$  and  $\nabla f(x) - \beta$   $\rightarrow$  0, then

$$f(x_{t+1}) \leq f(x_t) + \nabla f(x_t)^T (x_{t+1} - x_t) + \frac{\beta}{2} \| x_t - x_{t+1} \|_2^2$$

$$x_{t+1} - x_t = -\eta \nabla f(x_t) : \text{GD} \quad \text{since } \eta \nabla f(x_t) \rightarrow 0$$

$$f(x_{t+1}) - f(x_t) \leq \nabla f(x_t)^T (-\eta \nabla f(x_t)) + \frac{\beta}{2} \| \eta \nabla f(x_t) \|_2^2 : \text{GD}$$

:  $\leftarrow$  since  $\| \nabla f(x_t) \|_2 \rightarrow 0$

$$f(x_{t+1}) - f(x_t) \leq -\eta \| \nabla f(x_t) \|_2^2 + \frac{\beta}{2} \eta^2 \| \nabla f(x_t) \|_2^2$$

$$= \| \nabla f(x_t) \|_2^2 \left( \frac{\beta}{2} \eta^2 - 1 \right)$$

$$\text{so } 0 < \eta < \frac{2}{\beta} \quad \text{and } \left( \text{if } \eta > \frac{2}{\beta} \right)$$

$$\frac{f(x_{t+1}) - f(x_t)}{\frac{\beta \eta^2}{2} - 1} \geq \| \nabla f(x_t) \|_2^2 \geq 0$$

$$\text{so } \eta - \eta^2 \frac{\beta}{2} > 0$$

$\therefore$  (why)

. t b d  $\rightarrow$   $\rightarrow$   $\rightarrow$   $\rightarrow$

$$\sum_{t=0}^T \|\nabla f(x_t)\|_2^2 \geq \text{constant}$$

תנאי  
ת-ב

$$f(x_0) \left( \eta - \frac{\rho}{2} \eta^2 \right) \geq \left( f(x_0) - f(x_{t+1}) \right) \cdot \underbrace{\left( \eta - \frac{\rho}{2} \eta^2 \right)}_{\text{#} > 0 \text{ ו } 1} \geq \sum_{t=0}^T \|\nabla f(x_t)\|_2^2$$

הוכחה של קיומו של נקודה נסותית

הוכחה של קיומו של נקודה נסותית

$$\lim_{t \rightarrow \infty} \|\nabla f(x_t)\|_2^2 = 0$$

$$\lim_{t \rightarrow \infty} \|\nabla f(x_t)\|_2 = 0$$

QED



ענין סדרה נס

13) היבנה מושג ה-Margin וAccuracy . 1

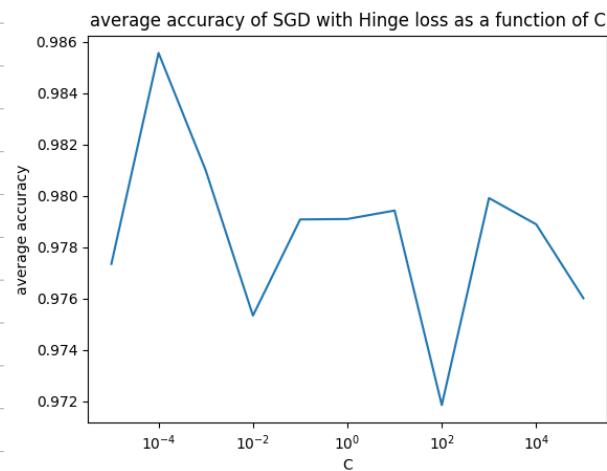
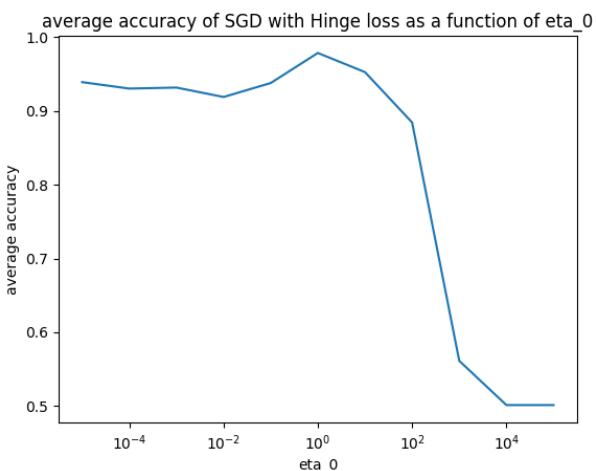
: פירוט

Q1 results:  
optimal eta\_0: 1  
optimal C: 0.0001  
accuracy of the best classifier: 0.9923

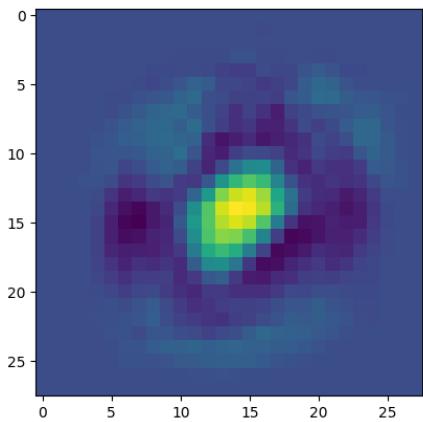
learning rate | יפ'ל | Cross Validation Classifier

$\eta_0 = 1$  | הגדלתו | .  $\eta_0 = \gamma$  | כוונת שיטות |

$10^{-4} = C$  | כוונת שיטות | סדרת כוכב | סדרת כוכב |



best classifier was image



Now, we'll see how to find y<sub>k</sub> for  $\omega$ )

Q2 results:

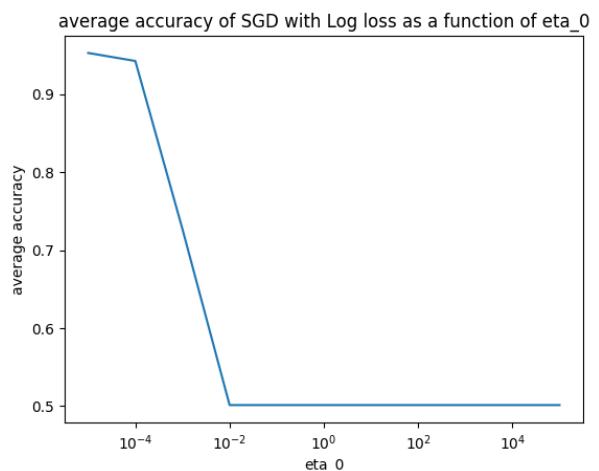
optimal eta\_0: 1e-05

accuracy of the best classifier: 0.9678

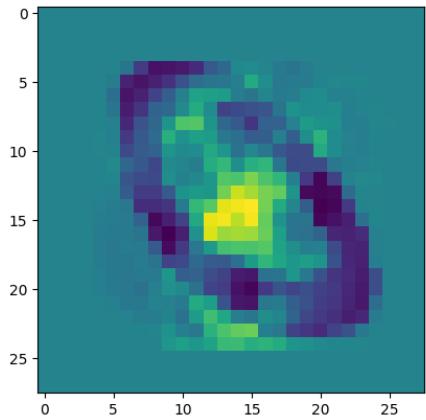
Ram

2  
XGD  
: SGD  
learning rate

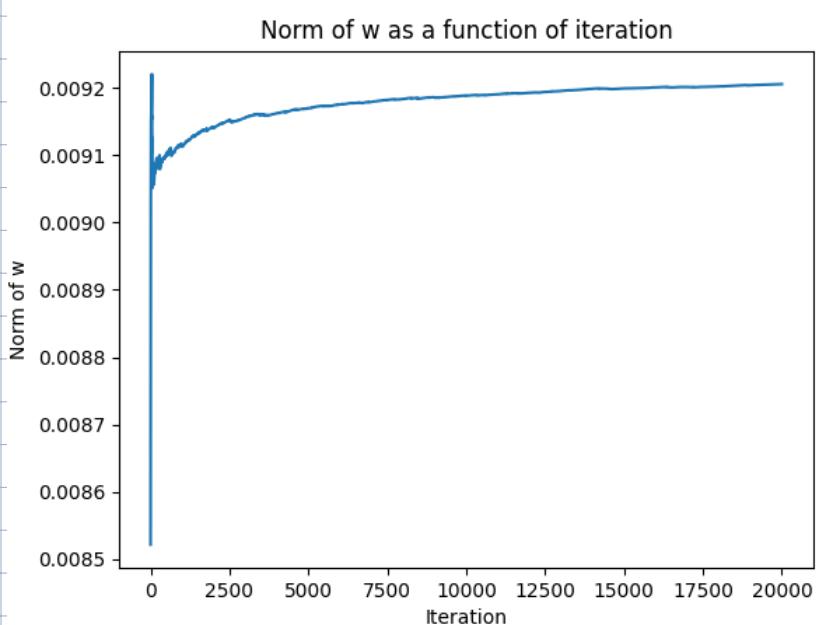
SGD learning rate vs accuracy  
eta\_0 = 10^-5 (opt) Cross Validation in  
accuracy 0.9678 : SGD with Log loss  
Hinge loss vs average accuracy



best classifier w vs image



מילויים נאכלה באלגוריתם גראדיינט  
 וריאנט אחד שמשתמש בפונקציית האפסון  
 ופונקציית האפסון כפונקציית מטרית



מילויים נאכלה באלגוריתם גראדיינט  
 וריאנט אחד שמשתמש בפונקציית האפסון  
 ופונקציית האפסון כפונקציית מטרית

מילויים נאכלה באלגוריתם גראדיינט  
 וריאנט אחד שמשתמש בפונקציית האפסון  
 ופונקציית האפסון כפונקציית מטרית